

Advanced Machine Learning (CST8506)

기말고사 예상문제 + 풀이 해설 (Final Exam Practice)

Name: Hye Ran Yoo | Student #: 041145212

파트	문항수	배점	범위
True/False	10	각 3점 (30점)	Week 9, 10, 11
Multiple Choice	20	각 3점 (60점)	Week 9, 10, 11
Written (주관식)	4	각 12~18점 (72점)	Week 9, 10, 11

True/False 함정 패턴 + 교수님 출제 스타일 반영 — 중간고사 분석 기반

PART 1: True / False (Q1 ~ Q10) — 각 3점, 총 30점

교수님 함정 패턴 복습: "always", "only", "identical", "cannot" 같은 절대 표현이 보이면 즉시 의심! 이름과 정의를 바꿔치기하는 패턴도 빈출.

Q1. In a class imbalance problem, accuracy is always a reliable metric for evaluating classifier performance.

FALSE

불균형 데이터(Imbalanced Data)에서 정확도(Accuracy)는 신뢰할 수 없는 지표입니다. 예: 양성 10건, 음성 990건인 경우 모든 것을 음성으로 예측해도 정확도가 99%가 되지만, 양성은 하나도 못 잡습니다. 이런 경우 Precision(정밀도), Recall(재현율), F1-measure가 더 적합합니다.

TIP: "always"가 핵심 함정. 불균형 데이터에서는 accuracy가 misleading!

Q2. Oversampling the minority class works by randomly duplicating instances of the minority class to balance the dataset.

TRUE

오버샘플링(Oversampling)은 소수 클래스(Minority Class)의 인스턴스를 복제(Duplicate)하여 다수 클래스와 균형을 맞추는 기법입니다. 단순한 방법이지만 동일한 인스턴스를 반복하여 과적합(Overfitting)의 위험이 있습니다. 이를 개선한 것이 SMOTE입니다.

TIP: 단순 복제(Duplicate) = Oversampling. 합성 생성(Synthetic) = SMOTE. 구분 필수!

Q3. SMOTE generates synthetic minority class instances by copying existing minority instances with small random noise added.

FALSE

SMOTE (Synthetic Minority Oversampling Technique)는 단순히 복사+노이즈가 아닙니다. 소수 클래스 인스턴스와 그 k-최근접 이웃(k-NN) 사이의 선분(Line Segment) 위에 새로운 합성 인스턴스를 생성합니다. 차이(Difference)를 구하고 0~1 사이 랜덤값을 곱해서 원래 인스턴스에 더하는 방식입니다.

TIP: SMOTE는 "copy+noise"가 아니라 "이웃 간 선분 위 보간(Interpolation)"! 방법론 설명이 미묘하게 틀린 함정.

Q4. The area under the ROC curve (AUC) for a model that performs random guessing is 0.5.

TRUE

ROC 곡선(Receiver Operating Characteristic Curve)에서 무작위 추측(Random Guessing) 모델은 대각선(Diagonal)을 따르며, 그 아래 면적(AUC, Area Under the Curve) = 0.5입니다. 완벽한 모델은 AUC = 1.0, 완전히 반대로 예측하면 AUC = 0.0입니다.

TIP: AUC: Random = 0.5, Perfect = 1.0. ROC 곡선의 x축은 FPR, y축은 TPR.

Q5. In Bagging, each bootstrap sample is created by sampling without replacement from the original training set.

FALSE

배깅(Bagging = Bootstrap AGGREGatING)에서 부트스트랩 샘플(Bootstrap Sample)은 원본 데이터에서 복원 추출(Sampling WITH Replacement)로 생성됩니다. "without"이 아니라 "with" replacement입니다. 복원 추출 덕분에 같은 인스턴스가 여러 번 뽑힐 수 있고, 약 63.2%의 원본 데이터가 각 샘플에 포함됩니다.

TIP: "without" ↔ "with" 바꿔치기 함정! Bagging = with replacement (복원 추출).

Q6. In AdaBoost, correctly classified instances have their weights increased in the next round so that the model focuses on easy examples.

FALSE

AdaBoost에서는 잘못 분류된(Misclassified) 인스턴스의 가중치를 증가시키고, 올바르게 분류된(Correctly Classified) 인스턴스의 가중치를 감소시킵니다. 이를 통해 다음 라운드의 분류기가 어려운 샘플(Hard Examples)에 집중하게 합니다. 문제는 정반대로 서술하여 함정을 만들었습니다.

TIP: 가중치 방향이 반대! Boosting = 틀린 것의 가중치 UP, 맞은 것 DOWN.

Q7. Random Forest combines Bagging with random feature selection at each split to create diverse decision trees.

TRUE

랜덤 포레스트(Random Forest)는 (1) 부트스트랩 샘플링(Bagging)으로 각 트리마다 다른 훈련 데이터를 사용하고, (2) 각 내부 노드(Internal Node)에서 무작위로 p 개의 특징(Feature)만 선택하여 분할 기준을 정합니다. 이 두 가지 무작위성(Randomness)으로 트리 간 다양성(Diversity)을 확보합니다.

TIP: Random Forest = Bagging + Random Feature Subset. 두 가지 랜덤성이 핵심.

Q8. The confidence of an association rule $\{X\} \rightarrow \{Y\}$ is calculated as the support of $\{X \cup Y\}$ divided by the total number of transactions.

FALSE

문제가 설명하는 공식은 Support(지지도)의 정의입니다. Confidence(신뢰도)의 정확한 공식은:
 $\text{Confidence}(\{X\} \rightarrow \{Y\}) = \text{Support}(\{X \cup Y\}) / \text{Support}(\{X\})$
즉, X 와 Y 가 함께 등장하는 비율을 X 가 등장하는 비율로 나눈 것입니다. 전체 트랜잭션 수로 나누는 것이 아닙니다.

TIP: Support = $\sigma(X \cup Y) / |T|$ (전체 나눔). Confidence = $\sigma(X \cup Y) / \sigma(X)$ (X 로 나눔). 분모가 다르다!

Q9. According to the Apriori principle, if an itemset is infrequent, then all of its supersets must also be infrequent.

TRUE

Apriori 원칙(Apriori Principle): 어떤 아이템셋이 비빈출(Infrequent)이면, 그것을 포함하는 모든 상위 아이템셋(Superset)도 반드시 비빈출입니다. 이는 지지도(Support)의 반단조 속성(Anti-monotone Property) 때문입니다 — 아이템셋이 커지면 지지도는 같거나 줄어듭니다. 이 원칙으로 후보 아이템셋 수를 대폭 줄여 연산량을 절감합니다.

TIP: Apriori = "Infrequent의 부모가 비빈출이면, 자식도 비빈출". 이것이 Pruning의 핵심 근거.

Q10. In association rule mining, rules generated from the same frequent itemset always have identical support and identical confidence values.

FALSE

같은 빈출 아이템셋(Frequent Itemset)에서 생성된 규칙들은 Support(지지도)는 동일합니다 (같은 아이템셋의 등장 빈도이므로). 그러나 Confidence(신뢰도)는 다를 수 있습니다. 예: {Milk,Beer}→{Diaper}와 {Diaper}→{Milk,Beer}의 Support는 같지만, 분모가 다르므로 Confidence는 다릅니다.

TIP: "identical support" 부분은 맞지만 "identical confidence"가 틀림. 부분적으로 맞는 함정!

True/False 정답 요약표

Q#	정답	핵심 키워드	함정 유형
1	F	Accuracy ≠ 불균형에서 신뢰	"always" 절대표현
2	T	Oversampling = 복제	정확한 설명
3	F	SMOTE = 이웃 간 보간	방법론 미묘하게 틀림
4	T	AUC Random = 0.5	정확한 설명
5	F	Bagging = WITH replacement	with↔without 바꿔치기
6	F	Boosting: 틀린 것 가중치 UP	방향 반대
7	T	RF = Bagging + Random Feature	정확한 설명
8	F	Confidence 분모 = $\sigma(X)$	Support↔Confidence 바꿔치기
9	T	Apriori: 비빈출→상위도 비빈출	정확한 설명
10	F	같은 Itemset: Support 같지만 Conf 다름	부분적 참 함정

PART 2: Multiple Choice (Q11 ~ Q30) — 각 3점, 총 60점

Q11. In a confusion matrix, a False Positive (FP) means:

- a) The model correctly predicted a positive instance.
- b) The model incorrectly predicted a negative instance as positive.
- c) The model incorrectly predicted a positive instance as negative.
- d) The model correctly predicted a negative instance.

정답: b) The model incorrectly predicted a negative instance as positive.

False Positive (FP, 거짓 양성, 오탐): 실제로는 Negative(음성)인데 모델이 Positive(양성)로 잘못 예측한 경우입니다.

- TP (True Positive): 실제 양성 → 양성 예측
- FP (False Positive): 실제 음성 → 양성 예측 (Type I Error)
- FN (False Negative): 실제 양성 → 음성 예측 (Type II Error)
- TN (True Negative): 실제 음성 → 음성 예측

Q12. The F1-measure is defined as:

- a) $(\text{Precision} + \text{Recall}) / 2$
- b) $2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$
- c) $\text{Precision} \times \text{Recall}$
- d) $(\text{TP} + \text{TN}) / (\text{TP} + \text{FP} + \text{FN} + \text{TN})$

정답: b) $2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$

F1-measure (F1 점수)는 Precision(정밀도)과 Recall(재현율)의 조화 평균(Harmonic Mean)입니다.

$$F1 = 2pr / (p + r)$$

(a)는 산술 평균, (d)는 Accuracy의 공식입니다. F1은 불균형 데이터에서 accuracy 대신 사용하는 핵심 지표입니다.

Q13. In an ROC curve, the x-axis and y-axis represent:

- a) $x = \text{Precision}$, $y = \text{Recall}$
- b) $x = \text{FPR (False Positive Rate)}$, $y = \text{TPR (True Positive Rate)}$
- c) $x = \text{Recall}$, $y = \text{Precision}$
- d) $x = \text{TPR}$, $y = \text{FPR}$

정답: b) $x = \text{FPR (False Positive Rate)}$, $y = \text{TPR (True Positive Rate)}$

ROC 곡선의 축: x 축 = $\text{FPR} = \text{FP} / (\text{FP} + \text{TN})$, y 축 = $\text{TPR} = \text{TP} / (\text{TP} + \text{FN}) = \text{Recall}$.

좋은 모델은 FPR이 낮고 TPR이 높으므로 곡선이 좌측 상단에 가깝습니다.

Q14. Which of the following correctly describes the SMOTE technique?

- a) It removes majority class instances to balance the dataset.
- b) It duplicates random minority class instances.
- c) It generates synthetic minority instances along line segments joining minority class nearest neighbors.
- d) It applies PCA to reduce the dimensionality of the minority class.

정답: c) It generates synthetic minority instances along line segments joining minority class nearest neighbors.

SMOTE는 소수 클래스 인스턴스와 그 k-최근접 이웃(k-NN) 사이의 선분(Line Segment) 위에서 보간(Interpolation)하여 합성 인스턴스를 생성합니다.

(a)는 Undersampling, (b)는 단순 Oversampling.

Q15. In the Local Outlier Factor (LOF) method, if the relative density of a point x is much greater than 1, it indicates that:

- a) x is a normal point with high density.
- b) x is surrounded by very dense neighbors and is therefore normal.
- c) x is a strong outlier because its density is much lower than that of its neighbors.
- d) x is the center of a dense cluster.

정답: c) x is a strong outlier because its density is much lower than that of its neighbors.

LOF (Local Outlier Factor, 지역 이상치 인자): $\text{relative_density}(x,k) = (\text{이웃들의 평균 밀도}) / (x\text{의 밀도})$.
이 값이 $\gg 1$ 이면 x 주변 밀도가 이웃들보다 훨씬 낮다는 뜻이므로 강한 이상치(Outlier)입니다.
값이 1이면 정상, < 1 이면 이웃보다 오히려 밀도가 높은 정상 지점입니다.

Q16. One-Class SVM (OCSVM) is designed to:

- a) Classify data into exactly two balanced classes.
- b) Learn a boundary around normal data points and identify outliers as points outside this boundary.
- c) Perform multi-class classification using multiple hyperplanes.
- d) Cluster data into groups based on density.

정답: b) Learn a boundary around normal data points and identify outliers as points outside this boundary.

One-Class SVM (OCSVM)은 정상 데이터만으로 학습하여 정상 영역의 경계(Boundary)를 만듭니다. 경계 밖에 떨어지는 데이터를 이상치(Outlier)로 판별합니다.
핵심: $f(x) = w \cdot \phi(x) - \rho \rightarrow f(x) \geq 0$ 이면 정상(Normal), $f(x) < 0$ 이면 이상치(Outlier).
 ν 파라미터로 이상치 비율을 조절합니다.

Q17. What are the two necessary conditions for ensemble methods to outperform a single base classifier?

- a) Base classifiers must be complex and trained on the full dataset.
- b) Base classifiers must be independent of each other and each must perform better than random guessing.
- c) Base classifiers must all use the same algorithm and be trained on identical data.
- d) Base classifiers must have zero training error and high variance.

정답: b) Base classifiers must be independent of each other and each must perform better than random guessing.

앙상블 방법(Ensemble Methods)이 단일 분류기보다 우수하려면:
① 기본 분류기들이 서로 독립적(Independent)이어야 합니다.
② 각 분류기의 오류율이 0.5 미만(이진 분류 기준, 즉 랜덤 추측보다 나아야) 합니다.

Q18. In Bagging, the probability of a particular training instance being selected in a single bootstrap sample (when n is large) is approximately:

- a) 0.5
- b) 0.368
- c) 0.632
- d) 1.0

정답: c) 0.632

부트스트랩 샘플에 특정 인스턴스가 포함될 확률 = $1 - (1 - 1/n)^n$.
n이 충분히 크면 $(1 - 1/n)^n \rightarrow 1/e \approx 0.368$ 이므로, 포함될 확률 = $1 - 0.368 = 0.632$ (약 63.2%).

Q19. Which statement best describes the key difference between Bagging and Boosting?

- a) Bagging uses weighted voting while Boosting uses simple majority voting.
- b) Bagging trains base classifiers independently in parallel, while Boosting trains them sequentially, focusing on previously misclassified instances.
- c) Bagging only works with decision trees, while Boosting works with any classifier.
- d) Bagging increases bias, while Boosting increases variance.

정답: b) Bagging trains base classifiers independently in parallel, while Boosting trains them sequentially, focusing on previously misclassified instances.

Bagging: 부트스트랩 샘플을 병렬(Parallel)로 독립 학습 → 분산(Variance) 감소에 초점.
Boosting: 이전 라운드의 오류에 집중하여 순차적(Sequential) 학습 → 편향(Bias) 감소에 초점.

Q20. In AdaBoost, the importance (alpha) of a base classifier is calculated as:

- a) $\alpha = \ln(1/\epsilon)$
- b) $\alpha = \frac{1}{2} \times \ln((1 - \epsilon) / \epsilon)$
- c) $\alpha = \epsilon / (1 - \epsilon)$
- d) $\alpha = 1 - \epsilon$

정답: b) $\alpha = \frac{1}{2} \times \ln((1 - \epsilon) / \epsilon)$

AdaBoost에서 분류기의 중요도(Importance) $\alpha = \frac{1}{2} \times \ln((1 - \epsilon) / \epsilon)$.
 ϵ = 오류율(Error Rate). ϵ 이 작을수록(정확할수록) α 가 커져 최종 투표에서 더 큰 영향력을 가집니다.
 $\epsilon = 0.5$ 이면 $\alpha = 0$ (랜덤 추측 수준 → 영향력 없음), $\epsilon > 0.5$ 이면 가중치를 리셋합니다.

Q21. If any intermediate round in AdaBoost produces an error rate higher than 50%, what happens?

- a) The algorithm terminates immediately.
- b) The weights are reverted back to $1/n$ and the resampling procedure is repeated.
- c) The classifier is given a negative weight.
- d) The training data is reshuffled randomly.

정답: b) The weights are reverted back to $1/n$ and the resampling procedure is repeated.

AdaBoost에서 중간 라운드의 에러율이 50%를 초과하면, 가중치를 초기 상태인 $1/n$ 으로 리셋하고 재샘플링을 반복합니다. 이는 해당 분류기가 랜덤 추측보다 못하다는 뜻이므로 무시하고 다시 시작하는 것입니다.

Q22. What distinguishes Random Forest from standard Bagging?

- a) Random Forest does not use bootstrap sampling.
- b) Random Forest randomly samples a subset of features at each split in addition to bootstrap sampling.
- c) Random Forest uses pruned decision trees while Bagging uses unpruned trees.
- d) Random Forest uses weighted voting while Bagging uses majority voting.

정답: b) Random Forest randomly samples a subset of features at each split in addition to bootstrap sampling.

Random Forest = Bagging + Random Feature Subset
Bagging과 동일하게 부트스트랩 샘플을 사용하지만, 추가로 각 내부 노드(Internal Node)에서 전체 특징 대신 무작위로 p 개의 특징만 선택하여 분할합니다. 이중 랜덤성으로 트리 간 상관관계를 낮추고 다양성(Diversity)을 높입니다.

Q23. Ensemble methods work best with base classifiers that are:

- a) Very stable and insensitive to training data changes.
- b) Unstable classifiers sensitive to minor perturbations in the training set.
- c) Simple models with very high bias.
- d) Pre-trained deep learning models.

정답: b) Unstable classifiers sensitive to minor perturbations in the training set.

양상불은 불안정한(Unstable) 분류기 — 학습 데이터의 작은 변화에도 모델이 크게 달라지는 분류기와 함께 쓸 때 효과가 큼. 예: 가지치기하지 않은 결정 트리(Unpruned Decision Trees), 신경망(ANN) 등. 안정적인 분류기(예: kNN)에는 효과가 적습니다.

Q24. Given a transaction database with 5 transactions, if the itemset {Beer, Diaper} appears in 3 transactions, what is the support of {Beer, Diaper}?

- a) 3
- b) 0.6
- c) 0.4
- d) 5/3

정답: b) 0.6

Support(지지도) = $\sigma(\text{Itemset}) / |T|$ = 아이템셋의 등장 횟수 / 전체 트랜잭션 수 = $3/5 = 0.6$.
(a)인 3은 Support Count(지지도 횟수)이지 Support(지지도, 비율)가 아닙니다.

Q25. Given the rule {Milk, Diaper} → {Beer} where $\sigma(\{Milk, Diaper, Beer\}) = 2$, $\sigma(\{Milk, Diaper\}) = 3$, and $|T| = 5$, the confidence of this rule is:

- a) $2/5 = 0.4$
- b) $3/5 = 0.6$
- c) $2/3 = 0.67$
- d) $3/2 = 1.5$

정답: c) 2/3 0.67

Confidence(신뢰도) = $\sigma(X \cup Y) / \sigma(X) = \sigma(\{Milk, Diaper, Beer\}) / \sigma(\{Milk, Diaper\}) = 2/3 = 0.67$.
Support(지지도) = $2/5 = 0.4$. Support와 Confidence의 분모가 다르다는 것이 핵심!

Q26. The Apriori principle states that:

- a) If an itemset is frequent, then all of its supersets must also be frequent.
- b) If an itemset is frequent, then all of its subsets must also be frequent.
- c) If an itemset is infrequent, then all of its subsets must also be infrequent.
- d) Support and confidence are always positively correlated.

정답: b) If an itemset is frequent, then all of its subsets must also be frequent.

Apriori 원칙: 빈출 아이템셋의 모든 부분집합(Subset)도 빈출이어야 합니다. 이의 대우(Contrapositive): 비빈출 아이템셋의 모든 상위집합(Superset)도 비빈출입니다.
(a)는 반대 — 빈출의 상위집합이 반드시 빈출인 건 아님. (c)는 부분집합 방향이 틀림.

Q27. In the Apriori algorithm, candidate pruning works by:

- a) Removing candidates whose support count is below the threshold.
- b) Removing candidate k-itemsets that contain any (k-1)-subset that is not frequent.
- c) Removing all itemsets that contain rare items.
- d) Removing candidates based on their confidence value.

정답: b) Removing candidate k-itemsets that contain any (k-1)-subset that is not frequent.

후보 가지치기(Candidate Pruning): 후보 k-아이템셋의 (k-1) 크기 부분집합 중 하나라도 비빈출인 것이 있으면 해당 후보를 제거합니다. Apriori 원칙에 근거합니다.
(a)는 Support Counting 단계이고, (d)는 Rule Generation 단계의 작업입니다.

Q28. What is the anti-monotone property of support?

- a) Support of an itemset always increases as items are added.
- b) Support of an itemset never exceeds the support of its subsets.
- c) Support is always equal to confidence.
- d) Support of an itemset is independent of its size.

정답: b) Support of an itemset never exceeds the support of its subsets.

반단조 속성 (Anti-monotone Property): 아이템셋이 커지면(아이템이 추가되면) Support는 같거나 줄어들기만 합니다. 즉, $\forall X \subseteq Y: s(X) \geq s(Y)$. 이 성질이 Apriori Pruning의 수학적 근거입니다.

Q29. If $|L| = k$ (a frequent itemset of size k), how many candidate association rules can be generated (excluding trivial rules)?

- a) k
- b) 2^k
- c) $2^k - 2$
- d) $k! - 1$

정답: c) $2^k - 2$

크기 k인 빈출 아이템셋에서 생성 가능한 후보 연관 규칙 수 = $2^k - 2$.
전체 부분집합 수 2^k 에서 공집합 $\rightarrow L$ ($\rightarrow L$)과 $L \rightarrow$ 공집합 ($L \rightarrow$)의 두 가지 자명한(Trivial) 규칙을 빼면 됩니다.

Q30. Given Precision = 0.5 and Recall = 0.8, what is the F1-measure?

- a) 0.65
- b) 0.625
- c) Approximately 0.62
- d) 0.80

정답: c) Approximately 0.62

$F1 = 2 \times p \times r / (p + r) = 2 \times 0.5 \times 0.8 / (0.5 + 0.8) = 0.8 / 1.3 \approx 0.615 \approx 0.62$
손 계산: 분자 = $2 \times 0.5 \times 0.8 = 0.8$. 분모 = 1.3. $0.8/1.3 = 8/13 \approx 0.615$.

TIP: 계산기 없이: 분수 8/13 $\approx$ 0.62로 근사. 소수점 둘째 자리까지만 충분.

객관식 정답 요약표

Q#	Ans	Q#	Ans	Q#	Ans	Q#	Ans
11	b	12	b	13	b	14	c
15	c	16	b	17	b	18	c
19	b	20	b	21	b	22	b
23	b	24	b	25	c	26	b
27	b	28	b	29	c	30	c

PART 3: Written Questions (Q31 ~ Q34) — 총 72점

Q31. Confusion Matrix 계산 (6+6+6 = 18 marks)

Consider the following confusion matrix for a medical test:

	Predicted YES	Predicted NO
Actual YES	40 (TP)	10 (FN)
Actual NO	20 (FP)	930 (TN)

(a) Calculate Precision, Recall, and F1-measure. (6 marks)

지표	공식	계산	결과
Precision	$TP / (TP + FP)$	$40 / (40 + 20) = 40/60$	0.667
Recall (TPR)	$TP / (TP + FN)$	$40 / (40 + 10) = 40/50$	0.8
F1-measure	$2pr / (p+r)$	$2 \times 0.667 \times 0.8 / (0.667 + 0.8)$	0.727

(b) Calculate the Accuracy. Is it a reliable metric here? Explain. (6 marks)

$$\text{Accuracy} = (TP + TN) / (TP + FP + FN + TN) = (40 + 930) / 1000 = 970 / 1000 = 0.97 \text{ (97\%)}$$

그러나 이 지표는 신뢰할 수 없습니다(Not Reliable). 데이터가 불균형(YES=50, NO=950)이며 다수 클래스(NO)가 압도적입니다. 모든 것을 NO로 예측해도 accuracy = 95%가 되지만 양성(YES)은 하나도 못 잡습니다. Precision(0.667)과 F1(0.727)이 accuracy(0.97)보다 훨씬 현실적인 성능 지표입니다.

(c) Calculate FPR and explain what it means in this context. (6 marks)

$$\text{FPR (False Positive Rate)} = FP / (FP + TN) = 20 / (20 + 930) = 20/950 \approx 0.021 \text{ (2.1\%)}$$

의미: 실제로 질병이 없는 사람(Actual NO) 950명 중 20명(2.1%)을 질병이 있다고 잘못 진단한 비율입니다. 의료 테스트에서 FPR은 불필요한 추가 검사나 환자 불안을 유발하므로 낮을수록 좋습니다.

Q32. Association Rule Mining 계산 (6+6+6 = 18 marks)

Given the following transaction database with minimum support count = 2:

TID	Items
1	A, B, C
2	A, B
3	A, C
4	B, C, D
5	A, B, C, D

(a) Find all frequent 1-itemsets and 2-itemsets. (6 marks)

Itemset	Count	Frequent?
---------	-------	-----------

{A}	4	(≥2)
{B}	4	
{C}	4	
{D}	2	

Itemset	Count	Frequent?
{A,B}	3	
{A,C}	3	
{A,D}	1	(가지치기)
{B,C}	3	
{B,D}	2	
{C,D}	2	

(b) Using the Apriori principle, which 3-itemset candidates can be pruned? Find frequent 3-itemsets. (6 marks)

빈출 2-itemsets: {A,B}, {A,C}, {B,C}, {B,D}, {C,D}. (단, {A,D}는 비빈출)

후보 3-itemsets (F2 × F2 방법):

- {A,B,C}: 부분집합 {A,B}, {A,C}, {B,C} → 모두 빈출 → 후보 유지
- {A,B,D}: 부분집합 {A,D}=1 → Apriori에 의해 가지치기(Pruned)
- {A,C,D}: 부분집합 {A,D}=1 → 가지치기
- {B,C,D}: 부분집합 {B,C}, {B,D}, {C,D} → 모두 빈출 → 후보 유지

Support Counting:

- $\sigma(\{A,B,C\}) = \text{TID } 1,5 \rightarrow 2$ Frequent
- $\sigma(\{B,C,D\}) = \text{TID } 4,5 \rightarrow 2$ Frequent

(c) Given the frequent itemset {A, B, C}, calculate the support and confidence of the rule {A} → {B, C}. (6 marks)

$$\text{Support}(\{A\} \rightarrow \{B,C\}) = \sigma(\{A,B,C\}) / |T| = 2/5 = 0.4$$

$$\text{Confidence}(\{A\} \rightarrow \{B,C\}) = \sigma(\{A,B,C\}) / \sigma(\{A\}) = 2/4 = 0.5$$

해석: 전체 트랜잭션 중 40%에서 A,B,C가 함께 등장하며, A를 구매한 사람 중 50%가 B와 C도 함께 구매합니다.

Q33. Bagging vs Boosting 비교 + 계산 (6+6+6 = 18 marks)

(a) Compare Bagging and Boosting in terms of: (i) sampling method, (ii) classifier training order, (iii) voting mechanism. (6 marks)

항목	Bagging	Boosting (AdaBoost)
(i) Sampling	Bootstrap (복원추출, WITH replacement). 각 샘플이 독립적	가중치 기반 샘플링. 이전 라운드의 오류에 따라 가중치 조절

(ii) Training Order	병렬(Parallel): 각 분류기가 독립적으로 학습	순차적(Sequential): 이전 분류기의 오류를 반영하여 다음 분류기 학습
(iii) Voting	단순 다수결(Majority Vote): 모든 분류기가 동일한 가중치	가중 투표(Weighted Vote): 정확한 분류기일수록 더 큰 가중치(α)

(b) In AdaBoost, a base classifier has an error rate $\epsilon = 0.3$. Calculate its importance α . (6 marks)

$$\alpha = \frac{1}{2} \times \ln\left(\frac{1 - \epsilon}{\epsilon}\right) = \frac{1}{2} \times \ln\left(\frac{0.7}{0.3}\right) = \frac{1}{2} \times \ln(2.333)$$

$$\ln(2.333) \quad 0.847$$

$$\alpha = \frac{1}{2} \times 0.847 \quad 0.424$$

손 계산 팁: $\ln(7/3) = \ln(7) - \ln(3) \quad 1.946 - 1.099 = 0.847$. 이것의 절반 0.42 .

(c) Given three classifiers with predictions below, determine the ensemble prediction using majority vote for a test point. (6 marks)

Classifier	Prediction
C1	+1 (Positive)
C2	-1 (Negative)
C3	+1 (Positive)

다수결(Majority Vote): +1이 2표, -1이 1표 → 양상불 예측 = +1 (Positive)
Bagging에서는 모든 분류기의 투표 가중치가 동일하므로 단순히 표 수를 셉니다.

Q34. 이상치 탐지 개념 + 계산 (6+6+6 = 18 marks)

(a) Name and briefly describe three different approaches to anomaly detection. (6 marks)

접근법	영어명	설명
통계적 방법	Statistical	데이터의 확률 분포 모델을 세우고, 확률이 매우 낮은 데이터를 이상치로 판별 (예: Grubbs' Test)
근접성 기반	Proximity-based	다른 점들과의 거리가 먼 점을 이상치로 판별. k번째 최근접 이웃까지의 거리를 이상치 점수로 사용
밀도 기반	Density-based (LOF)	주변 밀도가 이웃들의 밀도보다 현저히 낮은 점을 이상치로 판별. 상대 밀도(Relative Density) 활용

(b) In OCSVM, the decision function is $f(x) = w \cdot \phi(x) - \rho$. Explain what happens when $f(x) \geq 0$ and when $f(x) < 0$. What does the parameter ν control? (6 marks)

- $f(x) \geq 0$: 데이터 포인트 x 는 정상(Normal)으로 분류됩니다. 학습된 경계 안쪽에 위치합니다.
- $f(x) < 0$: 데이터 포인트 x 는 이상치(Outlier/Anomaly)로 분류됩니다. 경계 바깥에 위치합니다.

ν (nu) 파라미터: 전체 데이터 중 이상치로 분류될 것으로 예상되는 비율의 상한(Upper Bound on Fraction of Outliers)을 지정합니다. $\nu = 0.05$ 이면 약 5%의 데이터가 경계 밖으로 나갈 수 있도록 경계를 설정합니다.

(c) Explain the concept of Reconstruction-Based anomaly detection. Give one example of a method used for dimensionality reduction in this approach. (6 marks)

재구성 기반 이상치 탐지(Reconstruction-Based Anomaly Detection):

정상 데이터에는 저차원으로 표현할 수 있는 패턴이 존재한다고 가정합니다.

- ① 원본 데이터 x 를 저차원 공간으로 축소(Reduce)합니다.
- ② 저차원 표현을 다시 원래 공간으로 복원(Reconstruct)합니다 $\rightarrow \hat{x}$
- ③ 재구성 오차(Reconstruction Error) = $\|x - \hat{x}\|$ 을 계산합니다.
- ④ 재구성 오차가 큰 데이터 포인트를 이상치로 판별합니다.

차원 축소 방법 예시: PCA (Principal Component Analysis) 또는 Auto-encoder.

PART 4: Supplementary Questions — 교수님 수업 강조 포인트 기반

아래 문제들은 교수님이 수업 중 반복적으로 강조한 개념과 예시를 바탕으로 추가 출제합니다. 중간고사 분석 결과 교수님은 수업 시간에 강조한 포인트를 그대로 시험에 출제하는 경향이 있습니다.

4-1. Supplementary True / False (Q35 ~ Q49)

Q35. Ensemble methods such as Bagging and Boosting provide good explainability because we can explain the majority voting process to the end user.

FALSE

교수님이 수업에서 가장 강조한 포인트! 앙상블은 "왜 이런 결정을 내렸는가?"에 대답할 수 없습니다. 다수결(Majority Voting) 과정 자체는 설명 가능하지만, 각 개별 분류기가 왜(Why) 그런 예측을 했는지를 설명할 수 없습니다. 사용자가 원하는 것은 "10명의 의사가 투표했다"가 아니라 "왜 그 질병이라고 판단했는가"에 대한 짧고 유용한 설명입니다.

TIP: 교수님 원문: "The user is looking for exact explanation why the first classifier made that decision... not the explanation from 10 different decisions."

Q36. In Boosting (AdaBoost), all training samples are treated equally throughout the entire training process.

FALSE

Bagging에서는 모든 샘플을 동등하게 취급합니다 (equal weight). 그러나 Boosting(AdaBoost)에서는 매 라운드마다 가중치를 업데이트합니다 — 잘못 분류된 샘플의 가중치를 증가시키고, 올바르게 분류된 샘플의 가중치를 감소시킵니다. 교수님은 "시험 공부" 비유를 사용: Q-Learning을 못하면 다음 복습 때 Q-Learning에 더 집중하는 것과 같습니다.

TIP: 교수님 비유: "공부할 때 약한 부분에 더 집중하는 것 = Boosting의 핵심 원리"

Q37. In Bagging, it is guaranteed that every training instance will be included in every bootstrap sample.

FALSE

Bagging에서 복원 추출(WITH Replacement)을 사용하므로, 특정 인스턴스가 한 부트스트랩 샘플에서 빠질 확률이 있습니다. 실제로 n 이 충분히 크면 각 부트스트랩 샘플에 원본의 약 63.2%만 포함됩니다. 교수님 설명: "Even if you are weak in Q-learning, it would be possible to review ten times without touching Q-learning" — 이것이 Bagging의 한계.

TIP: "guaranteed"와 "every" = 절대 표현. Bagging에서 특정 샘플이 빠질 수 있음!

Q38. In AdaBoost, if an intermediate round produces an error rate greater than 50%, the algorithm immediately terminates.

FALSE

교수님이 명확히 설명: 에러율 > 50%이면 알고리즘이 종료되는 것이 아니라, 가중치를 $1/n$ 으로 리셋(Reset)하고 재샘플링을 반복합니다. 에러율 50% 초과 = 랜덤 추측(Random Guessing)보다 못함 → 해당 분류기를 무시하고 다시 시작.

TIP: "terminates" = 함정! 리셋하고 계속 진행하지, 종료하지 않음.

Q39. In Random Forest, base classifiers (decision trees) are pruned to reduce model complexity.

FALSE

교수님이 명시적으로 언급: Random Forest의 기본 분류기는 가지치기하지 않은(Unpruned) 결정 트리입니다. "base classifier are unpruned... we don't do any kind of post pruning." Pruning하지 않는 이유: 개별 트리의 높은 분산(Variance)을 앙상블이 자연스럽게 상쇄해주기 때문.

TIP: Random Forest = Unpruned Trees! 교수님이 직접 "no post pruning" 언급.

Q40. Association rules represent causal relationships between items (e.g., buying beer causes buying diapers).

FALSE

교수님이 여러 차례 반복 강조: 연관 규칙은 인과관계(Causality)가 아닌 동시 발생(Co-occurrence/Correlation)입니다. "It doesn't mean that if someone wants to buy beer, he or she must buy diapers before. It just shows the correlation, kind of correlation. It's not causality." 함께 구매되는 패턴이 있을 뿐, 하나가 다른 하나를 "원인"으로 만드는 것은 아닙니다.

TIP: 교수님 최다 반복 강조! Association Rule = Correlation $\neq$ Causation. 시험 단골!

Q41. In association rule mining, the quantity of each item purchased and the identity of the customer are important factors in the analysis.

FALSE

교수님이 명시적으로 언급: 연관 규칙 마이닝에서 수량(Quantity)과 고객 정보(Customer Identity)는 고려하지 않습니다. "What are the things here different? We don't have price... the quantity... nothing about the customers." 트랜잭션에 아이템이 존재하는지 여부(Yes/No)만 중요합니다.

TIP: 교수님 직접 언급한 포인트! 수량, 가격, 고객 정보 = Association Rule에서 무시.

Q42. The brute force approach for finding frequent itemsets is practical for large datasets with thousands of items.

FALSE

교수님이 강조: 아이템이 D개일 때 가능한 아이템셋 수 = $2^D - 1$ (공집합 제외). 6개 아이템만으로도 602개의 규칙, 1000개 아이템이면 수백만 개 이상. "This brute force search doesn't make sense." — 이것이 Apriori 알고리즘이 필요한 이유.

TIP: 교수님: "6개 아이템만으로도 602 rules. 천 개면? Brute force는 impossible!"

Q43. In AdaBoost, the final prediction is made using simple majority voting where all classifiers have equal influence.

FALSE

AdaBoost는 가중 투표(Weighted Majority Voting)를 사용합니다. 각 분류기의 중요도 α (alpha)에 따라 투표 가중치가 달라집니다. 교수님 비유: "의사 10명에게 의견을 받되, 가장 유명한 의사의 의견에 더 큰 비중을 두는 것"과 같습니다. $\alpha = \frac{1}{2} \times \ln((1-\epsilon)/\epsilon)$ 로 계산되며, 에러율이 낮은 분류기일수록 α 가 큼니다.

TIP: Simple majority vote = Bagging. Weighted majority vote = Boosting(AdaBoost). 혼동 금지!

Q44. In association rule mining, the two-step approach first generates rules and then finds frequent itemsets.

FALSE

순서가 반대! 올바른 두 단계(Two-step approach):
Step 1: 빈출 아이템셋 생성 (Frequent Itemset Generation) — Support 기준
Step 2: 규칙 생성 (Rule Generation) — Confidence 기준
교수님: "After finding the frequent itemsets... we should generate the rules."

TIP: 순서 바뀌치기 함정! Step 1 = Frequent Itemset (Support) → Step 2 = Rules (Confidence)

Q45. Ensemble methods are most effective when combined with stable classifiers like k-Nearest Neighbors (kNN).

FALSE

교수님 강조: 양상불은 불안정한(Unstable) 분류기와 함께 쓸 때 효과적입니다. 불안정 = 학습 데이터의 작은 변화에 모델이 크게 바뀜 (예: Unpruned Decision Tree, ANN). 안정적(Stable) 분류기 (예: kNN)는 학습 데이터가 바뀌어도 모델이 크게 변하지 않으므로 양상불 효과가 적습니다.

TIP: 교수님 핵심: "Unstable classifiers sensitive to minor perturbations" = 양상불의 최적 조건.

Q46. Bagging primarily aims to reduce bias in the model, while Boosting primarily aims to reduce variance.

FALSE

정반대입니다!
Bagging: 주로 분산(Variance)을 줄이는 데 초점. 여러 다른 훈련 데이터로 독립 학습 → 예측의 분산 감소.
Boosting: 주로 편향(Bias)을 줄이는 데 초점. 이전 오류에 집중하여 순차 학습 → 모델이 점점 정교해짐.

TIP: Bagging = Variance 감소, Boosting = Bias 감소. 교수님 시험에서 자주 바뀌서 출제!

Q47. In the Apriori algorithm, candidate k-itemsets are generated by merging two frequent (k-1)-itemsets whose first (k-2) items are identical.

TRUE

교수님이 직접 설명한 후보 생성(Candidate Generation) 방법: 두 빈출 (k-1)-아이템셋을 합병(Merge)하되, 처음 (k-2)개 아이템이 동일할 때만 합칩니다. 예: {A,B,C}와 {A,B,D}는 처음 2개(A,B)가 같으므로 합쳐서 {A,B,C,D}를 만듦.

TIP: 후보 생성 규칙: first (k-2) items identical → merge. 교수님이 예제로 설명.

Q48. In a confusion matrix, a high accuracy always means the model has high recall for the minority class.

FALSE

불균형 데이터에서 accuracy가 높아도 소수 클래스의 recall은 0%일 수 있습니다. 예: 양성 10건, 음성 990건 데이터에서 모든 것을 음성으로 예측하면 Accuracy = 99%이지만 Recall(양성) = 0/10 = 0%. 이것이 불균형 데이터에서 accuracy가 misleading한 이유입니다.

TIP: "always" + "high accuracy = high recall" = 이중 함정. 불균형 데이터의 핵심 개념!

Q49. The Apriori algorithm uses the anti-monotone property of support to prune candidate itemsets before counting their support.

TRUE

Apriori 알고리즘의 핵심 전략: 후보 아이템셋의 support를 계산하기 전에 반단조 속성(Anti-monotone Property)을 이용하여 가지치기(Pruning)합니다. 후보 k-itemset의 (k-1) 부분집합이 빈출이 아니면 → support 계산 없이 바로 제거. 이것이 연산량을 대폭 줄이는 핵심입니다.

TIP: 교수님: "Without finding the support, without calculating the support, that's why we use Apriori."

추가 T/F 정답 요약표 (Q35~Q49)

Q#	정답	핵심 키워드	교수님 강조도
35	F	Ensemble ≠ Explainable	★★★ 최다 강조
36	F	Boosting: 가중치 매 라운드 변경	★★★
37	F	Bagging: 63.2% 포함, 빠질 수 있음	★★
38	F	AdaBoost: $\epsilon > 50\% \rightarrow$ Reset (종료 아님)	★★★
39	F	Random Forest = Unpruned Trees	★★
40	F	Association Rule ≠ Causality	★★★ 최다 강조
41	F	수량/고객 정보 무시	★★
42	F	Brute Force = Impractical	★★
43	F	AdaBoost = Weighted Vote (≠ Simple)	★★★
44	F	Two-step: Itemset 먼저 → Rule 나중	★★
45	F	Ensemble + Unstable이 효과적	★★★
46	F	Bagging=Var ↓, Boosting=Bias ↓	★★★
47	T	Candidate Gen: first (k-2) identical	★★
48	F	High Accuracy ≠ High Recall (불균형)	★★★
49	T	Apriori: Support 계산 전에 Pruning	★★

4-2. Supplementary Written Questions (Q50 ~ Q53)

Q50. Explainability of Ensemble Methods (12 marks)

A student argues: "Ensemble methods like Bagging are explainable because we can tell the user that 10 different classifiers voted and we took the majority." Is this correct? Explain why or why not.

이 주장은 틀렸습니다 (Incorrect).

교수님의 핵심 논점:

- ① 다수결(Majority Voting) 과정 자체를 설명하는 것은 투명성(Transparency)이 아닙니다.
- ② 사용자(End User)가 원하는 것: "왜(Why) 첫 번째 분류기가 그런 결정을 내렸는가?", "왜 두 번째 분류기가 다른 결정을 내렸는가?"에 대한 구체적 설명.
- ③ 수백 개의 특징(Features)과 수백만 개의 데이터로 훈련된 앙상블에서는 단일 분류기조차 설명하기 어려운데, 10개의 분류기를 모두 설명하는 것은 더욱 불가능합니다.
- ④ "10명의 의사가 투표했으니 이 질병입니다"는 설명이 아니라 결과의 요약일 뿐입니다.

결론: Ensemble methods are not explainable (설명 불가능). 이것이 앙상블의 주요 한계입니다.

TIP: 교수님이 수업에서 학생 질문에 직접 답변하며 강조한 주제. 서술형 출제 가능성 매우 높음!

Q51. AdaBoost Weight Update Process (12 marks)

Consider a training set with 10 samples. At round 1, the initial weights are all equal ($1/10 = 0.1$). Classifier C1 correctly classifies samples 1-7 but misclassifies samples 8, 9, and 10. The error rate $\epsilon_1 = 0.3$.

(a) Calculate the classifier importance α_1 . (4 marks)

$$\alpha_1 = \frac{1}{2} \times \ln\left(\frac{1 - \epsilon_1}{\epsilon_1}\right) = \frac{1}{2} \times \ln(0.7 / 0.3) = \frac{1}{2} \times \ln(2.333)$$

$\ln(2.333) \quad 0.847$
 $\alpha_1 \quad 0.424$

(b) Describe what happens to the weights of correctly and incorrectly classified samples. (4 marks)

- 올바르게 분류된 샘플 (1-7): 가중치가 감소합니다.
 $w_{\text{new}} = w_{\text{old}} \times e^{(-\alpha_1)} / Z$ (Z = 정규화 상수)
 $e^{(-0.424)} \quad 0.655 \rightarrow$ 기존 가중치의 약 65.5%로 줄어듦
- 잘못 분류된 샘플 (8-10): 가중치가 증가합니다.
 $w_{\text{new}} = w_{\text{old}} \times e^{(+\alpha_1)} / Z$
 $e^{(+0.424)} \quad 1.528 \rightarrow$ 기존 가중치의 약 152.8%로 늘어남

핵심: 가중치의 합은 항상 1이 되도록 정규화(Normalization)합니다.

(c) In round 2, will sample 8 have a higher or lower probability of being selected? Why? (4 marks)

샘플 8은 round 1에서 잘못 분류되었으므로 가중치가 증가했습니다. 따라서 round 2에서 선택될 확률이 높아집니다.

교수님의 "룰렛 휠(Roulette Wheel)" 비유: 가중치가 높은 샘플일수록 룰렛에서 차지하는 면적이 넓어져 선택될 확률이 높아집니다. 이를 통해 다음 분류기가 이전에 틀렸던 "어려운 샘플"에 더 집중하게 됩니다.

Q52. Hyperparameter Tuning (12 marks)

(a) What is the difference between a parameter and a hyperparameter? Give an example for each. (4 marks)

구분	Parameter (매개변수)	Hyperparameter (하이퍼파라미터)
정의	학습 과정에서 자동으로 학습되는 값	학습 전에 사용자가 설정하는 값
예시	K-Means의 최종 Centroid 위치, SVM의 w 벡터	K-Means의 K 값, Random Forest의 트리 수

(b) Name and briefly describe three approaches to hyperparameter tuning. (4 marks)

방법	영어명	설명
1	Grid Search	가능한 하이퍼파라미터 값의 모든 조합을 시도. 철저하지만 시간이 오래 걸림.
2	Random Search	가능한 값에서 무작위로 조합을 선택하여 시도. Grid보다 효율적.
3	Manual / Best Practice	논문이나 이전 연구에서 사용된 값을 참조. 예: batch size = 32 or 64가 널리 사용됨.

(c) Explain the difference between batch, iteration, and epoch in training. (4 marks)

- Batch: 한 번의 가중치 업데이트에 사용되는 훈련 데이터의 부분집합. Batch size = 32이면 32개 샘플로 1회 업데이트.
- Iteration (반복): 하나의 배치를 처리하여 가중치를 1회 업데이트하는 과정.
- Epoch (에폭): 전체 훈련 데이터를 1회 완전히 순회하는 것.

관계: 만약 1000개 샘플, batch size = 100이면 → 1 epoch = 10 iterations.

Q53. Association Rule Mining Applications (12 marks)

(a) Give two practical applications of association rule mining besides market basket analysis. (4 marks)

- ① 보험 사기 탐지(Insurance Fraud Detection): 사기 청구에서 반복 등장하는 특정 요소 조합(예: 사고 빈도 높은 지역 + 특정 보험 유형)을 발견.
 - ② 추천 시스템(Recommendation System): 온라인 쇼핑에서 "이 상품을 구매한 고객이 함께 구매한 상품" 추천. 예: 노트북 구매 → 마우스, 키보드 추천.
- 교수님 추가 언급: 다중 레이블 분류(Multi-label Classification)에서 레이블 간 상관관계 분석, 질병 증상 연관성 탐지 등.

(b) In supermarkets, how can association rules be used in two opposite strategies for product placement? (4 marks)

교수님이 수업에서 설명한 두 가지 상반된 전략:

전략 1 — 인접 배치(Close Placement): 연관 상품을 가까이 배치하여 고객 편의성 증대. 예: 기저귀와 맥주를 같은 통로에 배치 → 함께 구매 유도.

전략 2 — 원거리 배치(Far Placement): 연관 상품을 일부러 멀리 배치하여 고객이 매장을 돌아다니게 함 → 이동 경로에서 다른 상품도 보고 추가 구매를 유도. 교수님: "sometimes they put relevant things far away... they want to encourage to buy more."

(c) Association rules are updated periodically. Explain why. (4 marks)

연관 규칙은 트랜잭션 데이터에 기반하므로, 소비 패턴이 변하면 규칙도 변합니다.

예시:

- 계절 변화: 추수감사절(Thanksgiving)에는 칠면조(Turkey)와 관련 식재료의 동시 구매가 급증.
- 시간 경과: 지난 3개월의 트랜잭션을 분석하여 규칙을 도출하고, 다음 기간에 적용. 이후 새로운 트랜잭션 데이터로 규칙을 갱신.

교수님: "Association changes... you can look at last year season and put the same kind of thing. It's not static."

PART 5: 교수님 강조 포인트 최종 정리 — 시험 전 반드시 확인!

아래는 교수님이 수업 녹취록과 최종 요약에서 반복적으로 강조한 핵심 포인트입니다. 시험 직전에 이 부분만 빠르게 복습하세요.

Week 9: Imbalanced Class Problem

개념	핵심 정리
Accuracy의 함정	불균형 데이터에서 accuracy는 misleading. 99% accuracy라도 minority class를 하나도 못 잡을 수 있음. → F1, Precision, Recall 사용
Oversampling vs SMOTE	Oversampling = 단순 복제(Duplicate). SMOTE = k-NN 간 선분 위 보간(Interpolation)으로 합성 생성. 방법론 차이 정확히 구분!
ROC/AUC 핵심 수치	AUC: Random Guessing = 0.5, Perfect = 1.0. ROC 곡선: x축 = FPR, y축 = TPR.
LOF 해석	relative_density $\gg 1$ → Outlier (밀도가 이웃보다 낮음). 1 → Normal.
OCSVM 핵심	$f(x) \geq 0$ → Normal, $f(x) < 0$ → Outlier. v = 이상치 비율의 상한.
재구성 기반 탐지	원본 → 축소 → 복원 → 재구성 오차가 큰 것 = Outlier. 방법: PCA, Auto-encoder.

Week 10: Classifier Fusion / Ensemble

개념	핵심 정리
Bagging vs Boosting	Bagging: 병렬, 복원추출, 동일 가중치, Variance ↓ Boosting: 순차적, 가중치 변경, Weighted Vote, Bias ↓
Bagging 복원추출	WITH replacement! 약 63.2%만 포함. "without"으로 바꿔치기하는 함정 주의.
AdaBoost 가중치 방향	틀린 샘플 → 가중치 UP ($e^{(+\alpha)}$). 맞은 샘플 → 가중치 DOWN ($e^{(-\alpha)}$).
AdaBoost $\epsilon > 0.5$	에러율 > 50% → 종료 아님! 가중치를 $1/n$ 으로 리셋하고 재시작.
AdaBoost α 공식	$\alpha = \frac{1}{2} \times \ln((1-\epsilon)/\epsilon)$. ϵ 작을수록 α 큼 → 더 큰 투표 가중치.
Random Forest 특징	Bagging + Random Feature Subset. Unpruned trees 사용. No post-pruning!
Unstable Classifier	앙상블은 불안정한 분류기(Decision Tree, ANN)와 효과적. kNN 같은 안정적 분류기에는 효과 낮음.
Explainability ★★★	앙상블 최대 약점! Majority Vote 과정 설명 ≠ Explainability. 사용자는 "왜?"를 원함.

Week 11: Association Rule Mining

개념	핵심 정리
Correlation $\neq$ Causation	★★★ 교수님 최다 강조! 연관 규칙은 동시 발생(Co-occurrence)일 뿐, 인과관계(Causality)가 아님.
무시되는 정보	수량(Quantity), 가격(Price), 고객 정보(Customer ID) → Association Rule에서 무시. 존재 여부만 중요.

Support vs Confidence	Support = $\sigma(XUY) / T $ (전체로 나눔) Confidence = $\sigma(XUY) / \sigma(X)$ (X로 나눔). 분모가 다르다!
같은 Itemset의 규칙들	Support는 동일 (같은 Union). Confidence는 다를 수 있음 (분모가 다르므로).
Apriori 원칙	Frequent의 모든 Subset도 Frequent. 대우: Infrequent의 모든 Superset도 Infrequent.
Anti-monotone Property	아이템셋이 커지면 Support는 같거나 줄어듦. $\forall X \subseteq Y: s(X) \geq s(Y)$. Pruning의 수학적 근거.
Two-step Approach	Step 1: Frequent Itemset 생성 (Support 기준). Step 2: Rule 생성 (Confidence 기준). 순서 중요!
Candidate Generation	두 Frequent (k-1)-itemset을 합병: 처음 (k-2) 아이템이 동일할 때. 합병 후 Pruning 수행.
Pruning 방법	후보 k-itemset의 (k-1) 부분집합이 Frequent가 아니면 → Support 계산 없이 제거!
Brute Force 불가	D items → $2^D - 1$ itemsets, $3^D - 2^{D+1} + 1$ rules. D=6이면 602 rules. 실용적이지 않음.

Hyperparameter Tuning (교수님 마지막 수업)

개념	핵심 정리
Parameter vs Hyperparameter	Parameter = 학습 중 자동 결정 (e.g., centroid) Hyperparameter = 학습 전 설정 (e.g., K, tree 수, learning rate)
Tuning 방법 4가지	Manual Search, Grid Search, Random Search, Best Practice (논문 참조)
Batch vs Iteration vs Epoch	Batch = 데이터 부분집합, Iteration = 1회 업데이트, Epoch = 전체 데이터 1회 순회
Loss Functions	MAE (Mean Absolute Error), MSE (Mean Squared Error), Cross-Entropy

시험 함정 패턴 최종 체크리스트

#	함정 패턴	예시	올바른 답
1	"always", "never", "guaranteed" 절대 표현	"Accuracy is always reliable"	대부분 FALSE
2	"with" ↔ "without" 키워드 바꿔치기	"Bagging uses without replacement"	WITH replacement!
3	방향 반대 증가↔감소	"AdaBoost: correct → weight UP"	Misclassified → UP!
4	정의 바꿔치기 Support ↔ Confidence	"Confidence = $\sigma(XUY) / T $ "	그건 Support! Conf = $\sigma(XUY)/\sigma(X)$
5	부분적 참 A는 맞고 B는 틀림	"Same itemset → same support AND same confidence"	Support만 동일! Confidence는 다름
6	순서 바꿔치기	"Two-step: Rules first, then Itemsets"	Itemsets first!

7	Bias ↔ Variance 혼동	"Bagging reduces Bias"	Bagging = Variance ↓ Boosting = Bias ↓
8	Causation ↔ Correlation	"Association rules = causal"	Correlation only!

이 문제지를 3회 이상 반복하고, 특히 계산 문제(Confusion Matrix, Apriori 테이블, AdaBoost α)는 손으로 직접 풀어보세요. 교수님 시험의 핵심은 "개념의 미묘한 차이"를 구분하는 것입니다. 화이팅!